

# **Week2 Presentation**


**Multinomial Classification**

**Learning Rate, Preprocessing**

# Index

- Multinomial Classification
- Softmax & Cross-entropy
- Application & Tips
  - Learning Rate
  - Data Preprocessing
  - Overfitting
  - Data sets & Learning


# Multinomial Classification



- 여러 Label을 가지는 Classification을 Multinomial classification이라고 함.
- 이는 여러번의 Binary Classification으로 정의 가능함.
- 예제) A or not, B or not, C or not 이 세 번의 Binary Classification으로 Multinomial 구현


# Multinomial Classification

$$\begin{bmatrix} w_{A1} & w_{A2} & w_{A3} \\ w_{B1} & w_{B2} & w_{B3} \\ w_{C1} & w_{C2} & w_{C3} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} w_{A1}x_1 + w_{A2}x_2 + w_{A3}x_3 \\ w_{B1}x_1 + w_{B2}x_2 + w_{B3}x_3 \\ w_{C1}x_1 + w_{C2}x_2 + w_{C3}x_3 \end{bmatrix}$$



- 원래는  $w_1, w_2, w_3$  3개의 벡터를 사용해서 3번 연산했음.
- Weight의 row를 늘려 한번에 연산 가능하게 변환함.

# Softmax



- Softmax란, 어떤 결과 값에 대응하여 그 probability를 구해주는 함수.
- 각 값들은 모두 0 ~ 1 사이의 값에 해당하며, 그 값들을 다 더했을 때 1이 나옴.
- 따라서 이를 확률, 비율로 사용 가능함.

# Softmax

- 왜 Softmax를 사용해야 하는가.
  - Softmax는 Multinomial Classification에서 가장 큰 확률을 가지는 Feature를 쉽게 찾을 수 있게 해준다.
  - Argmax라는 함수(어떤 행렬의 최대값을 구함)와 같이 유용하게 사용할 수 있음.

# Cross-entropy

CROSS-ENTROPY

$S(Y) = \bar{Y}$

$L = Y$

$D(S, L) = - \sum_i L_i \log(S_i)$

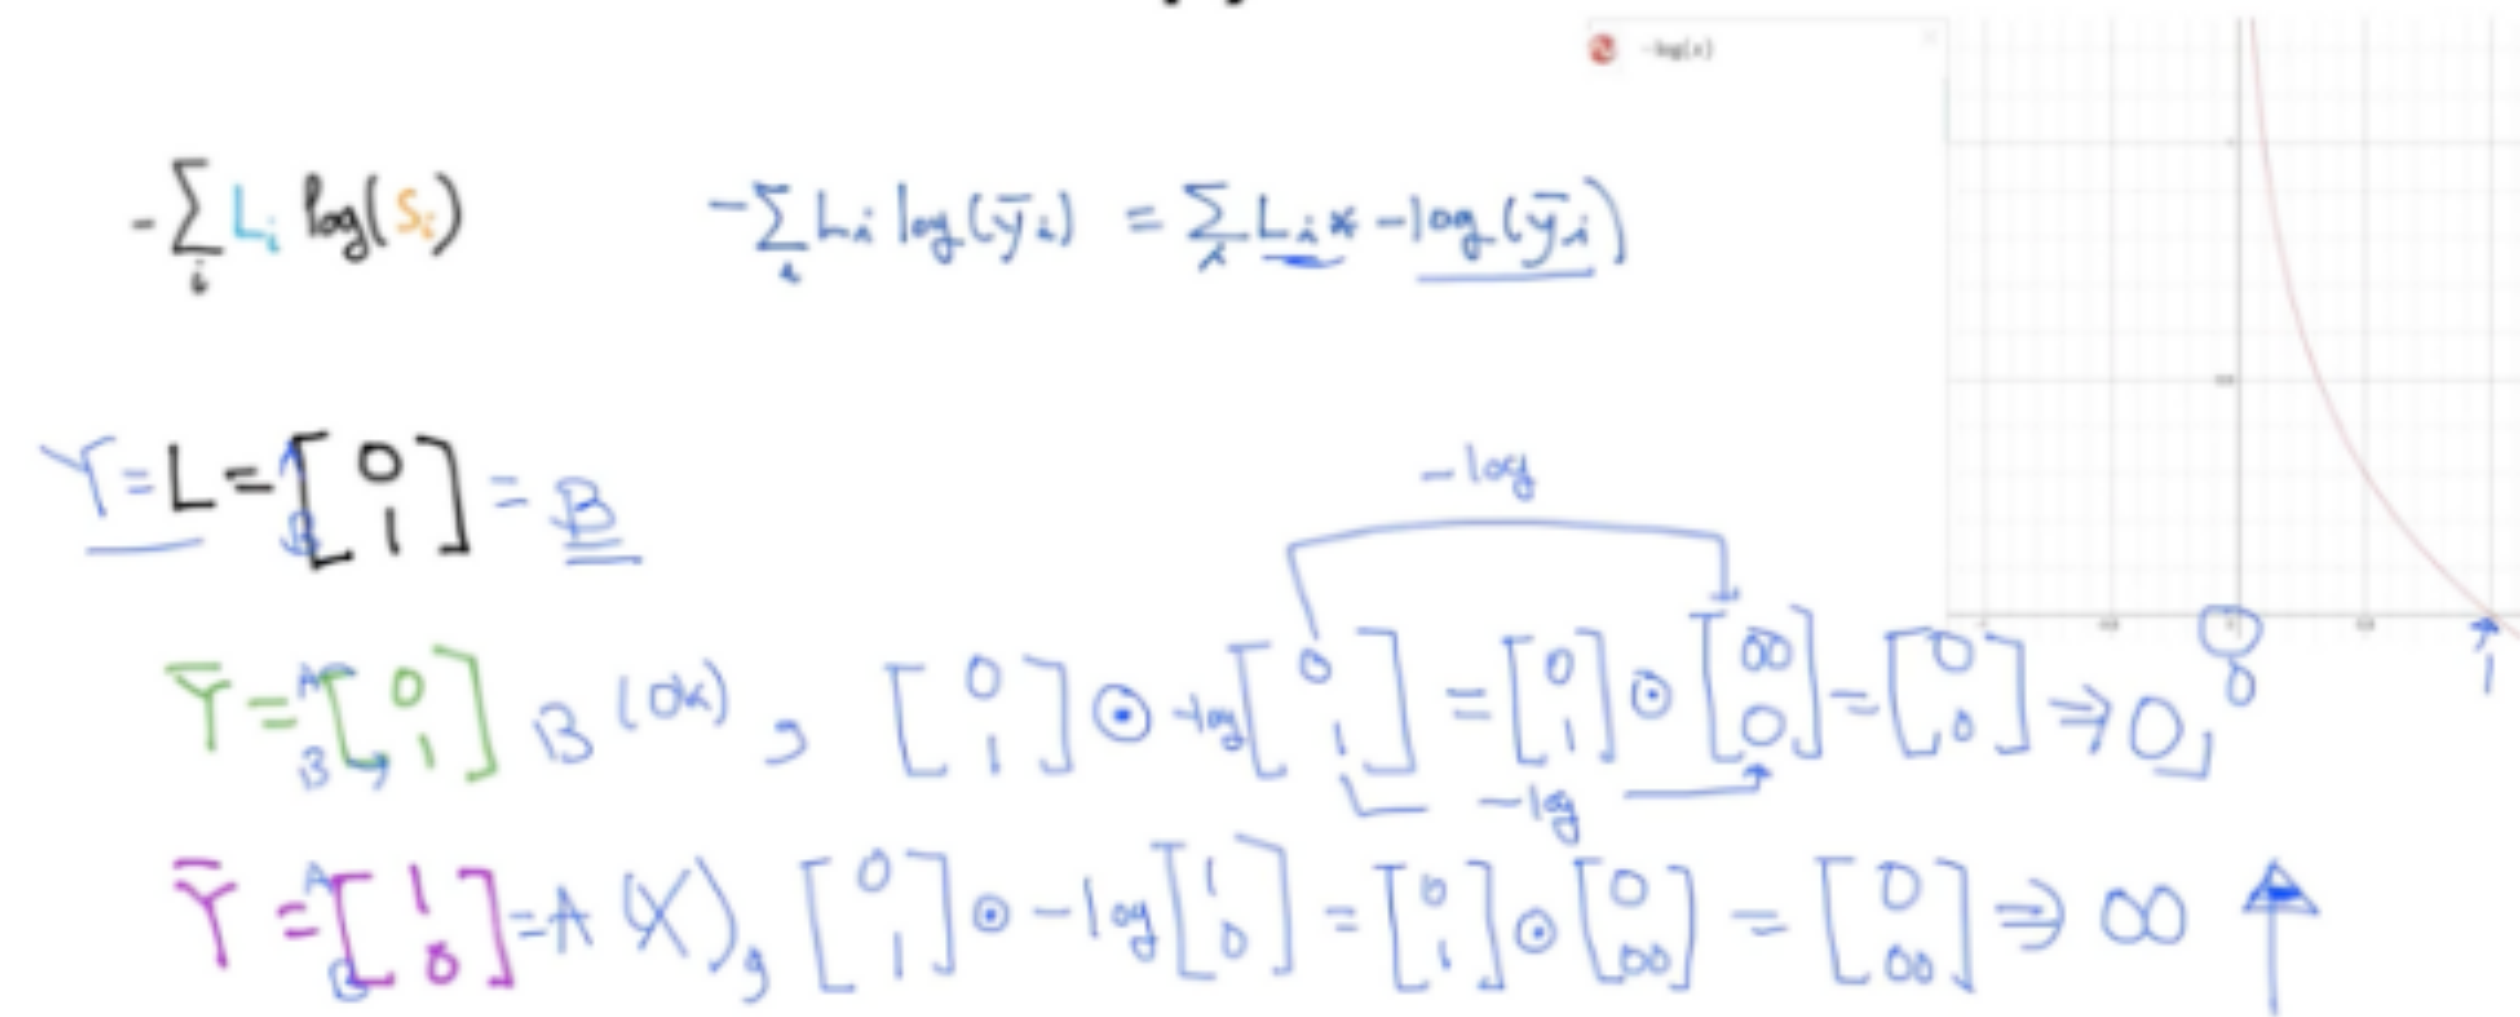
0.7
0.2
0.1

1.0
0.0
0.0

- Cross-entropy는 Cost function의 일종으로, 주로 Softmax와 함께 사용된다.
- S는 Softmax의 결과값, L은 실제 정답 Label을 뜻한다.

# Cross-entropy

## Cross-entropy cost function



$\mathcal{L} = \frac{1}{N} \sum_i \mathcal{D}(s(w x_i + b), L_i)$

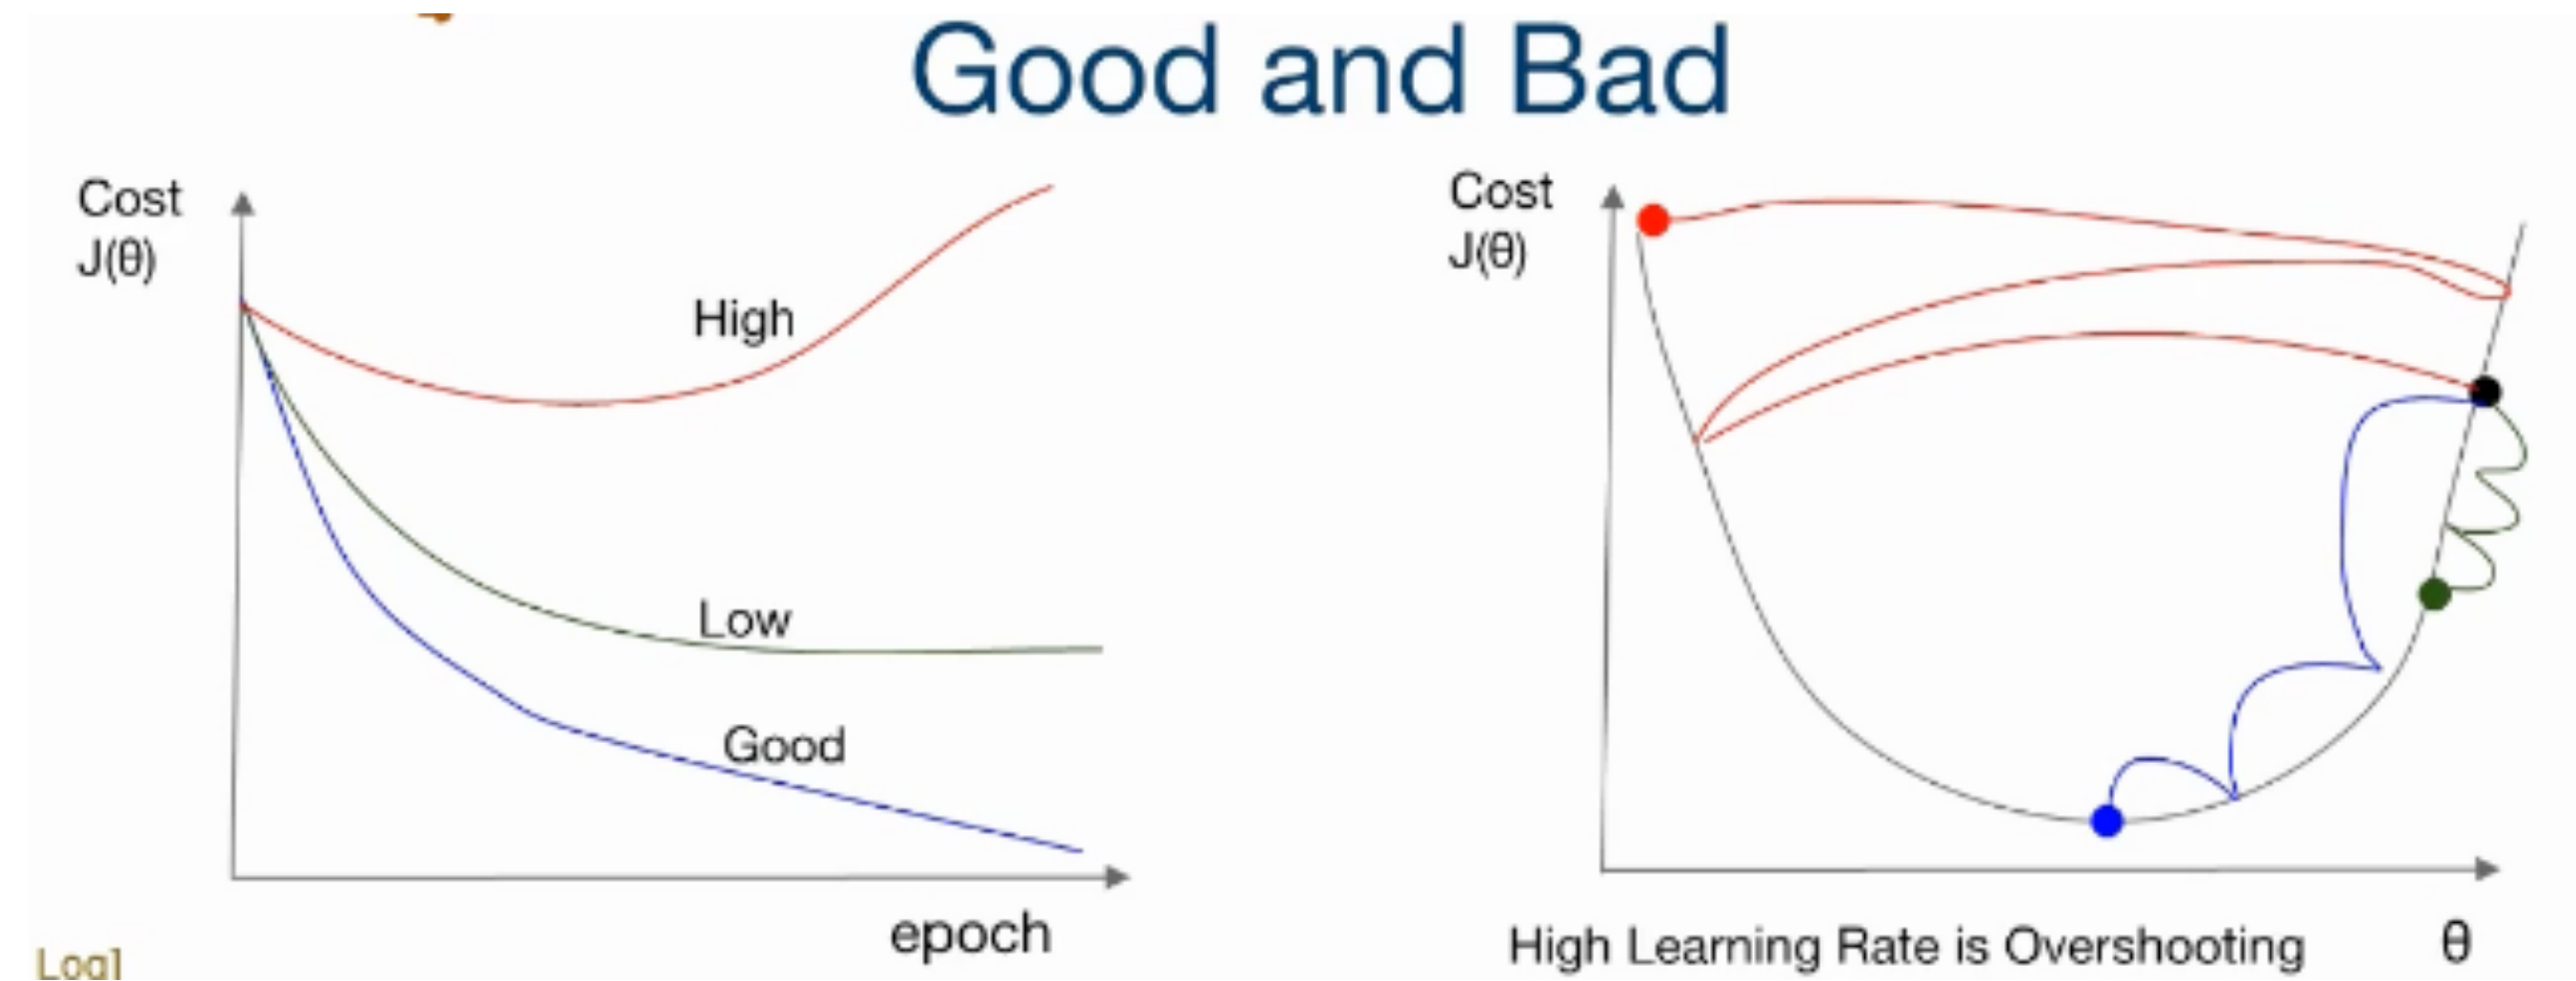
LOSS

TRAINING SET

- 왜 log를 취하는가 : Softmax를 거치므로 범위는 0 ~ 1, 0 일때 무한대, 1일 때 0인 비용을 할당
- Element-wise multiplication (요소별 곱) : 행렬의 같은 row 끼리 곱셈을 하는 방식

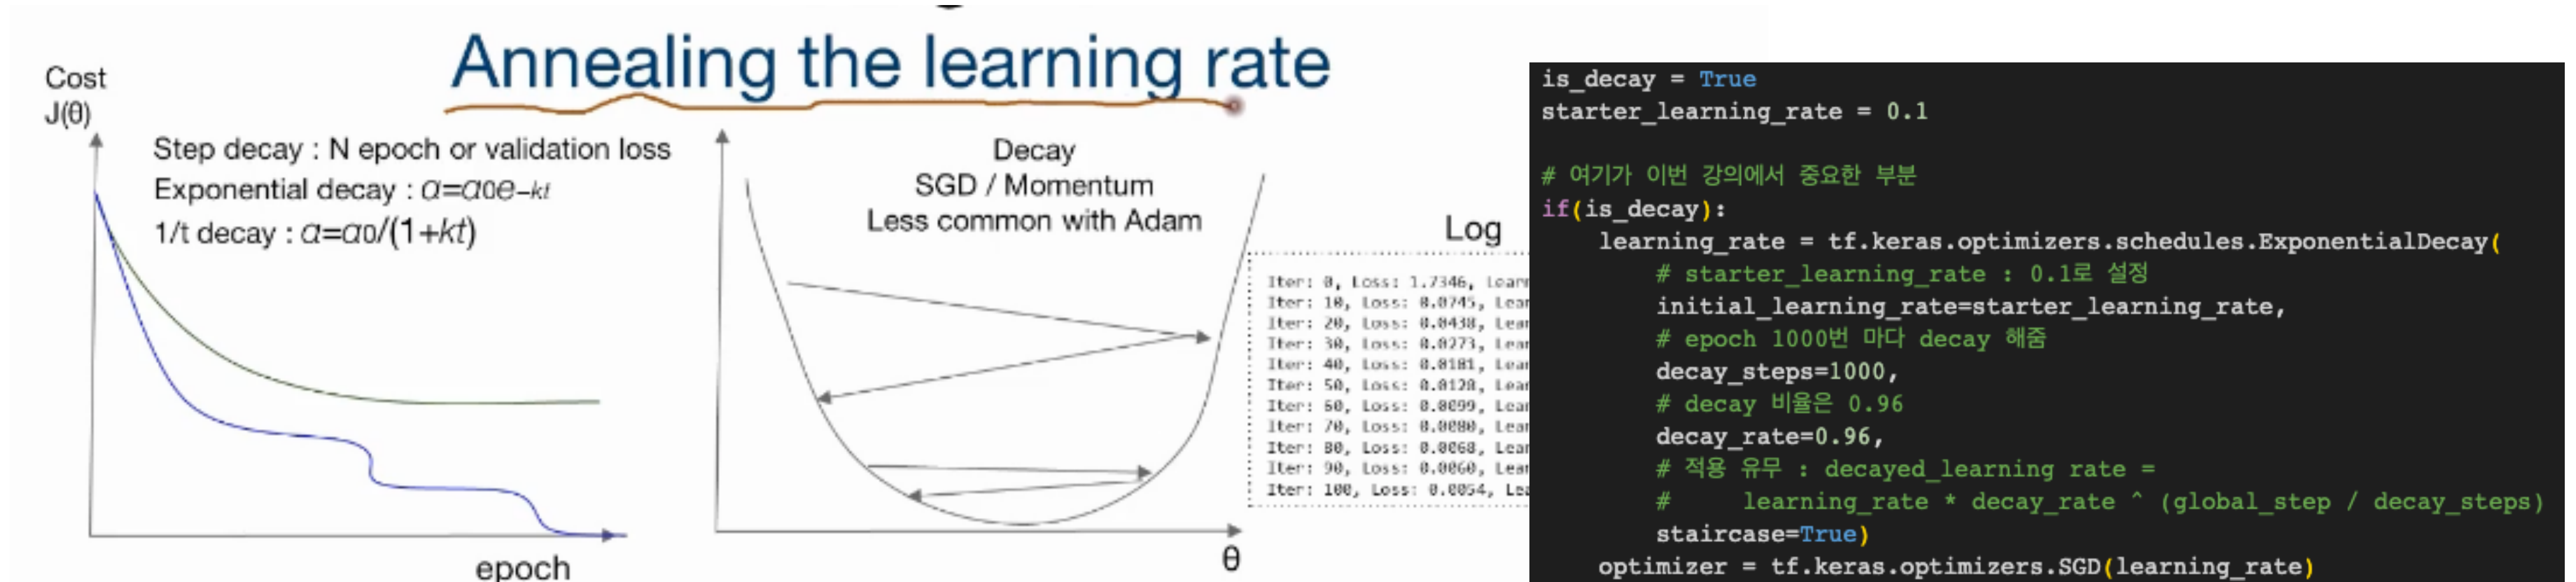


# Learning Rate



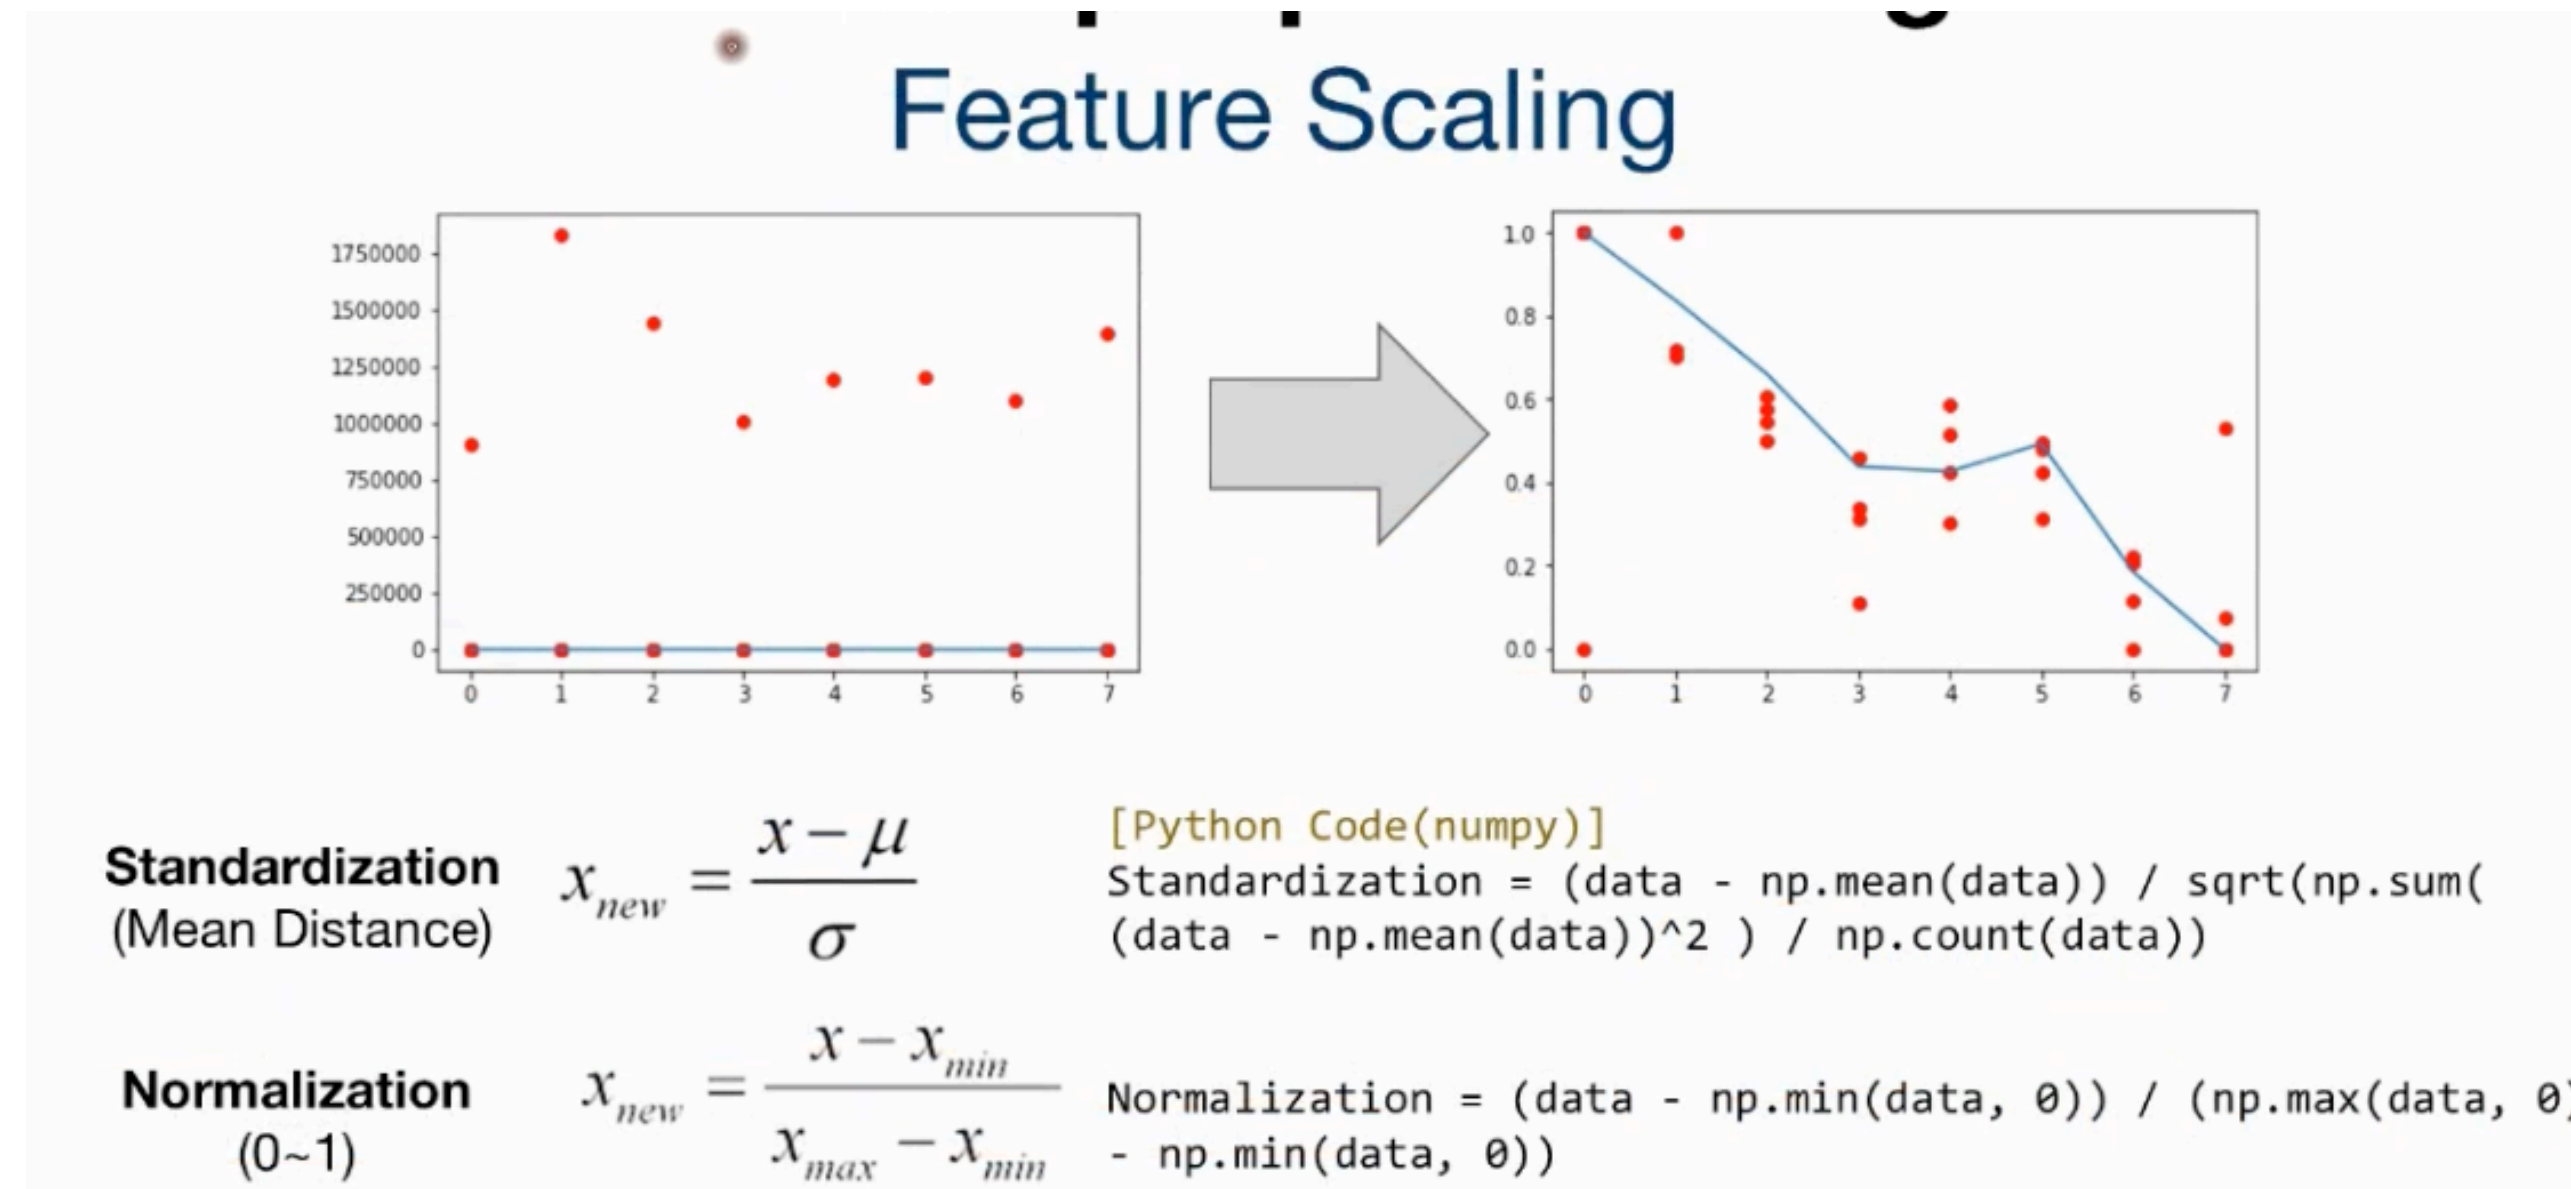
- Learning rate는 Gradient descent를 얼마나 적용할 지 결정하는 변수
- 너무 크면 발산하여 minimum에 도달 불가하고, 작으면 시간이 매우 오래 걸림

# Learning Rate



- 따라서 Learning rate를 상황에 따라 적절히 조절하는 것이 학습에 매우 유용하다.
- 이를 Learning rate decay라고 부르며, Step decay, Exponential decay 등이 있다.

# Data Preprocessing



```
def normalization(data):  
    # 수식 : x = x-xmin / xmax - xmin  
    numerator = data - np.min(data, 0)  
    denominator = np.max(data, 0) - np.min(data, 0)  
    return numerator / denominator
```

- 튜는 데이터들을 처리해주어야 학습에 있어서 효율적이고 정확한 학습이 된다.
- 그 방법으로는 Standardization(표준화)와 Normalization(정규화) 가 있다.

# Overfitting



- Overfitting이란 모델이 데이터 셋에 너무 맞춰서 학습된 경우를 말한다.
- 이 경우에 dataset에 있는 data로 test시 결과는 매우 좋지만, dataset에 있지 않는 data로 test시 결과가 좋지 않다.

# Overfitting


## How to solve

- Get more train data
  - 결국에 train data가 많아질 수록, 더 많은 데이터들을 다루기 때문에 Overfitting 방지
- Smaller set of features
  - feature의 개수가 작을 수록, weight의 개수도 줄어 variance가 줄어들게 된다.
  - PCA (주성분 분석) : 차원을 낮춰줌.



# Overfitting

## How to solve



- Regularization 방식은 Loss function에 어떤 term을 두어 튜닝 변수들을 제어함.
- 이는 Loss function의 안정화에 기여함.

# Data sets & Learning

## Data sets

- Training / Validation Data set partitioning
  - 어떠한 dataset에서 제대로 Train과 Validation set을 나누는 것이 중요하다.
- Anomaly detection (이상 감지)
  - GAN Network를 통해 Unusual data를 탐지하여 Dataset을 깔끔하게 한다.
  - 적대적 생성 신경망이라고 하며, 두 시스템의 경쟁을 통해 학습한다.

# Data sets & Learning

## Learning

	Online Learning	Batch(Offline) Learning
Data	Fresh	Static
Network	connected	disconnected
Model	Updating	Static
Weight	Tunning	initialize
Infra(GPU)	Always	Per call
Application	Realtime Process	Stopping
Priority	Speed	Correctness

- Online vs Batch Learning
- Online은 실시간으로 업데이트 되며, 속도를 중요시할 때 사용.
- Batch는 Offline에서 Static하게 Update하며, 정확성을 중요시 할 때 사용.



# Data sets & Learning

## Learning

- Fine Tuning / Feature Extraction
  - Fine tuning은 기존의 weight 값을 미세 조정하는 방식을 뜻함. 기존의 모델에 새로운 것들을 추가 할 때 기존 weight만 조금 바꿔 다른 데이터 셋들도 처리 가능하게 함.
  - Feature Extraction은 특징을 추출하는 방식으로, 특정 특징에 대해서만 추가로 학습하게 하는 방식
- Efficient Models
  - 실제 Field에서는 Model의 경량화가 서비스의 속도를 좌지우지 하기 때문에, fully connected layer에서 1x1 convolution으로 결과를 도출하면 size 줄어들어 경량화!

# **Thank you for Listening**

**Multinomial Classification**

**Learning Rate, Preprocessing**